

NER Financiero con BETO + LoRA

Proyecto Final Modulo 2 - Diplomado en AI & LLM for Financial Markets - ITAM
Gerardo Hurtado - Junio 2026

Resumen

Se construyo un sistema de Reconocimiento de Entidades Nombradas (NER) para texto financiero en espanol mediante fine-tuning eficiente (LoRA) de BETO. El sistema reconoce 5 categorias: instrumentos financieros, montos, plazos, tasas y entidades regulatorias, usando esquema BIO. Se comparo el rango LoRA $r=8, 16$ y 32 , encontrando $r=16$ como configuracion optima ($F1=0.880$ en test, totalmente reproducible mediante control explicito de semillas aleatorias). Durante el desarrollo se detecto y corrigio un problema critico de memorizacion de vocabulario que producia un $F1$ artificialmente perfecto (Seccion 3). Adicionalmente se realizo una evaluacion cualitativa en parrafos de texto natural (Seccion 6), revelando patrones de error utiles para iteraciones futuras.

1. Enfoque del Dataset

Se eligio generar un dataset sintetico mediante plantillas en lugar de anotar manualmente texto real (Opcion A ampliada del enunciado), priorizando velocidad de iteracion y control total sobre el etiquetado BIO. El dataset combina vocabulario financiero mexicano (CETES, TIIE, Banxico, CNBV) con terminos internacionales (swap, forward, Fed, JP Morgan), usando 9 plantillas sintacticas distintas mas oraciones negativas sin entidades.

Caso	Convencion
'25 puntos base'	Una sola entidad TASA
'100 millones de pesos'	Una sola entidad MONTO (frase completa)
'a 91 dias'	La preposicion 'a' queda fuera; solo '91 dias' es PLAZO
'CETES91'	Dos tokens: 'CETES' INSTR + '91' PLAZO
'Banco de Mexico'	Entidad completa de 3 tokens bajo B-/I-ENTIDAD

2. Dataset y Arquitectura del Fine-tuning

Aspecto	Valor
Modelo base	dccuchile/bert-base-spanish-wwm-cased (BETO)
Ejemplos train / val / test	~315 / ~48 / ~79 (val y test con vocab_pool='heldout')
LoRA target_modules	query, value (proyecciones de self-attention)
Epochs / batch / LR	30 / 8 / 0.001 (LR alto, tipico en LoRA)
Reproducibilidad	seed=42 fijado en RNG global, get_peft_model() y TrainingArguments (seed, data_seed)

2.1 Alineacion de subtokens (pieza tecnica central)

BETO usa WordPiece y puede dividir una palabra en varios subtokens (ej. 'UDIBONOS' -> 'UDI', '##BON', '##OS'). La solucion (alignment.py) usa word_ids() del tokenizer: el primer subtoken de cada palabra recibe la etiqueta BIO original; los subtokens adicionales y los tokens especiales ([CLS], [SEP], [PAD]) reciben el indice -100 que PyTorch CrossEntropyLoss ignora. Verificado con 12 tests usando el tokenizador real de BETO.

3. Correccion Critica: Memorizacion de Vocabulario

Problema detectado. Con el mismo vocabulario en train y val/test, el modelo alcanzo $eval_f1=1.0$ desde la epoca 4 (train_loss final 0.0002) - memorizacion, no aprendizaje del patron BIO. **Solucion.** Se dividio el vocabulario de cada categoria en pools disjuntos TRAIN/HELDOUT; val y test usan exclusivamente palabras nunca vistas en entrenamiento. Disjuncion verificada programaticamente (overlap=0 en las 5 categorias).

Metrica	Antes (vocab compartido)	Despues (vocab disjunto)
eval_f1 (val)	1.0000 desde epoca 4	0.8934 ($r=16$, convergencia gradual)

4. Comparacion LoRA r=8 vs r=16 vs r=32 (test set)

r	alpha	Params entrenables	F1	Precision	Recall
8	16	0.277%	0.8030	0.7644	0.8457
16	32	0.545%	0.8802	0.8622	0.8989
32	64	1.076%	0.8571	0.8235	0.8936

r=16 es optimo. El salto r=8->r=16 mejora F1 en +0.094. De r=16 a r=32 el F1 empeora (0.8802 -> 0.8571) mientras los parametros entrenables se duplican - senal de que mas capacidad ya no ayuda con un dataset de este tamaño. Resultado verificado reproducible: dos corridas independientes de r=16 con seed=42 produjeron F1 identico.

5. Resultados por Entidad y Analisis de Errores (test set, r=16)

Entidad	Precision	Recall	F1	Support
MONTO	1.000	1.000	1.000	16
TASA	1.000	1.000	1.000	32
PLAZO	0.951	1.000	0.975	39
INSTR	0.821	0.852	0.836	54
ENTIDAD	0.706	0.766	0.735	47

INSTR es la entidad mas dificil (F1=0.836): terminos heldout (BONDES, UDIBONOS, CDS) son los mas dificiles de generalizar. **ENTIDAD tiene el F1 mas bajo** (0.735); error caracteristico: en 'JP Morgan subio la tasa en 8.25%', el modelo predijo B-ENTIDAD para 'JP' pero I-INSTR para 'Morgan' en vez de I-ENTIDAD. **MONTO, TASA y PLAZO generalizan casi perfectamente** (F1>=0.975) por su estructura numerica predecible.

6. Evaluacion Cualitativa en Texto Natural

Mas alla del test set sintetico, se probó inference.py sobre 4 parrafos de texto financiero realista (comunicados de politica monetaria, subastas, mezclado con texto no-financiero). Esta evaluacion revela patrones de error no visibles en el test set, construido con las mismas plantillas que el entrenamiento.

Lo que funciono correctamente:

Cero falsos positivos en oraciones no financieras (futbol, clima) en el parrafo mixto. Entidades multi-token largas correctas: 'Banco de Mexico', 'Bolsa Mexicana de Valores', 'Standard & Poor's'. Montos complejos correctos: '500 millones de pesos', '10 mil millones de pesos'.

Patrones de error identificados:

Patron	Ejemplo observado	Causa probable
Sustantivo generico como entidad	'banca multiple' → banca ENTIDAD, multiple INSTR	El modelo sobre-predice en sustantivos financieros sin instrumento especifico asociado
Nombre propio compuesto	'JP Morgan' → JP ENTIDAD, Morgan INSTR	Mismo error que en test set: la segunda palabra del nombre se confunde con instrumento
Palabra generica de plazo	'de corto plazo' → plazo PLAZO	La palabra 'plazo' aislada (sin numero) se confunde con una entidad PLAZO real
Puntuacion pegada a la entidad	'Bonos M ,' incluido como INSTR	Bug menor de tokenizacion: la coma deberia recibir etiqueta O, no I-INSTR

Estos errores son consistentes con las limitaciones esperadas de un dataset sintetico pequeno: el modelo generaliza bien patrones estructurales (numero+unidad) pero es menos robusto ante sustantivos financieros genericos y nombres propios compuestos no vistos en una forma similar durante el entrenamiento.

7. Limitaciones

(1) Dataset sintetico por plantillas - no captura toda la variabilidad sintactica del espanol financiero real. (2) MONTO tiene el menor numero de valores unicos heldout, lo que pudo favorecer artificialmente su F1 perfecto. (3) ENTIDAD mezcla instituciones (Banxico) con

nombres propios compuestos (JP Morgan) de estructura sintactica distinta. (4) La evaluacion cualitativa (Seccion 6) confirma sobre-prediccion en sustantivos financieros genericos sin instrumento especifico asociado, y un bug menor de tokenizacion con puntuacion pegada a entidades.

Referencias

- Hu, E. et al. (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR.
- Cañete, J. et al. (2020). *Spanish Pre-Trained BERT Model and Evaluation Data (BETO)*. PML4DC.
- sequeval - github.com/chakki-works/sequeval